

COASTAL RESILIENCE CHALLENGE

RÉSUMÉ

Mon modèle se base sur le principe suivant : diviser pour mieux comprendre. Ce principe s'applique de deux manières. Tout d'abord via une classification des images dans trois catégories géographiques : la campagne (countryside), la banlieue (suburbs) et la ville (city). Ces catégories sont les divisé de manière très naïve en fonction de la proportion de pixels verts ou marrons dans l'image. En plus de cette division, mon modèle se découpe en deux catégories de sous-modèles, le rôle du premier étant de guider le second dans ses prédictions en altérant l'image d'origine. C'est modèles sont des modèles Yolo.

MODÈLE 1

ABORDER LE PROBLÈME AVEC UNE VUE D'ENSEMBLE

Le modèle 1 va chercher à identifier les **zones** résidentielles et commerciales. Ainsi, il ne va non pas se concentrer sur des batiments mais bien sur des ensembles de bâtiments et sur leurs alentours.

INTERMÉDIAIRE

COMMUNIQUER L'INFORMATION AU MODÈLE 2

Pour que le modèle 1 puisse efficacement transmettre au modèle 2 quelles sont les zones identifiées, il faut altérer l'image. Ici, c'est fait via un code 'intermédiaire' qui change la teinte de régions dans l'image en fonction de l'appartenance à une zone ou à l'autre. (fig 1)

MODÈLE 2

IDENTIFICATION DES 4 LABELS SUR LES IMAGES ALTÉRÉES

Le modèle 2 prend donc en entrée des images labellisées au préalable qui ont été altérées sur la base des informations fournies par le modèle 1. Il cherche alors à identifier les 4 types de bâtiments dans les zones colorées.

RÉSULTATS

Au travers de cette méthodologie, j'ai cherché à rendre mon modèle plus performant sur un faible nombre de données d'entraînement (environ 80 images concentrées sur la banlieue pour le modèle 1 et le modèle 2, ces images sont ensuite augmentées via les paramètres proposés par Yolo). Ce peu de données labellisées est bien la conséquence d'un manque de temps. Malgré cela, le modèle semble fonctionner sans être pour autant très performant donnant un MAP de 0.23 sur les données de test. (fig. 2)

LIMITATIONS

Il est important de noter que ce modèle (subdivisé en 2x3 sous-modèles) requière la labellisation de plus de données qu'un modèle simple. En effet, même si la classification selon la typologie d'environnement n'est qu'une division des images en sous-groupes, pour que le modèle soit fonctionnel, il faut tout de même un nombre suffisant d'images pour chaque sous-modèle. Pour ce qui est du modèle 1, il faut remarquer que si les données de test n'avaient pas été des images de 512x512, on aurait pu faire l'identification des zones commerciales et résidentielles sur une plus grande échelle avant de redécouper ces images en 512x512. Cela aurait permis de labelliser les données bien plus efficacement mais aussi d'entraîner le modèle sur des images plus grandes où les zones sont facilement reconnaissables.

PERSPECTIVES

Au delà de l'augmentation plus que nécessaire du nombre de données labellisées, on peut voir d'autres perspectives d'amélioration. Tout d'abord, l'altération de la teinte des images nous fait perdre les informations liées à la chrominance. Il aurait été préférable de travailler avec des images en RGBA en transportant l'information liée au type de zone via le canal alpha. Pour ce faire, il faut modifier le nombre de canaux en entrée dans l'architecture de Yolo. J'ai aussi essayé d'utiliser une architecture U-net avec 4 canaux, mais les résultats ont été peu concluants. Il serait aussi certainement judicieux d'utiliser des techniques de traitement d'images comme la transformée de Hough pour rendre les contours des bâtiments plus visibles. Enfin, on pourrait aussi utiliser un GAN pour augmenter la quantité de données d'entraînement.



Figure 1. Image altérée



Figure 2. Identification sur une image test